CVSmart

L'intelligence qui trie vos talents

Rapport de présentation de l'application

Fonctionnalités, fonctionnement, architecture technique et état du projet

Version 1.2 · 29 octobre 2026
CIBLE RH Emploi

1. Résumé

CVSmart est une application web développée pour **CIBLE RH Emploi**. Elle automatise le tri des candidatures : elle lit un lot de CV (PDF, Word ou documents scannés), en extrait les informations du candidat, classe chaque CV dans un domaine professionnel, attribue un score sur 100 et range les fichiers dans des dossiers. Elle peut aussi récupérer directement les CV reçus dans la boîte mail RH.

50	171	9	17
domaines professionnels	métiers reconnus	pages dans l'application	informations extraites par CV

Les recruteurs gardent la main : les CV dont le classement est incertain sont placés dans une file de validation, et chaque décision humaine sert à améliorer le modèle (apprentissage à partir des corrections). L'interface est entièrement en français.

2. Objectifs

- **Gagner du temps** : trier en quelques secondes des dizaines de CV qui demanderaient des heures de lecture.
- **Structurer les candidatures** : produire un tableau Excel homogène (identité, contact, formation, expérience, compétences, score).
- **Retrouver rapidement les bons profils** : filtrer par domaine, expérience, niveau d'études ou compétence, et comparer les CV à une offre d'emploi.
- **S'améliorer avec l'usage** : chaque correction faite par un recruteur rend le classement plus précis.

3. Fonctionnalités

L'application est organisée en neuf pages accessibles depuis le menu latéral.

Page	Rôle
Accueil	Présentation de l'outil et accès rapide au choix d'un dossier de CV.
Analyser	Analyse tous les CV d'un dossier local, avec progression et journal en direct.
Emails	Connexion à la boîte mail RH (IMAP), récupération des pièces jointes, recherche par sujet, expéditeur, date ou nom de fichier, analyse puis déplacement des emails traités dans un dossier « CV traités ».
Résultats	Totaux, répartition par domaine, export Excel.
Filtrer	Filtres par domaine, expérience minimale, niveau d'études, compétences, sexe, ville, âge et recherche libre ; export ou copie de la sélection dans un dossier.
Validation	File des CV incertains : le recruteur choisit parmi les domaines proposés (avec leur probabilité) ou un autre domaine, et peut corriger les informations extraites.
Apprentissage	Précision mesurée (globale et par domaine), corrections récentes, réentraînement du modèle.

Correspondance	Collage d'une offre d'emploi et classement des CV selon leur adéquation.
Paramètres	Seuil de confiance, identifiants de messagerie, remise à zéro de la session ou de l'apprentissage, liste des domaines configurés.

4. Fonctionnement

Chaque CV suit le même parcours en six étapes.

4.1 Lecture du document

Le texte est extrait avec PyMuPDF pour les PDF et python-docx pour les fichiers Word. Si un PDF contient moins de 300 caractères lisibles (CV scanné), l'application passe par la reconnaissance de caractères (OCR, RapidOCR) à 200 dpi. Le format Word ancien (`.doc`) n'est pas lisible : il faut le convertir en PDF ou en DOCX.

4.2 Extraction des informations

Des règles de reconnaissance de texte extraient 17 informations :

Catégorie	Informations
Identité	Nom, prénom, âge, sexe, situation familiale, nationalité, ville
Contact	Email, téléphone (formats camerounais, français et internationaux)
Parcours	Niveau d'études, établissement, années d'expérience, poste actuel
Compétences	Compétences, langues, certifications

Quand une information est introuvable, l'application inscrit **RAS** plutôt que d'inventer une valeur. Quelques règles importantes :

- **Âge** : une date n'est retenue comme date de naissance que si elle suit « né(e) le » ou « date de naissance ».
- **Sexe** : civilité dans l'en-tête du CV, puis prénom connu, puis accords grammaticaux (« née le », « mariée »).
- **Expérience** : mention explicite (« 5 ans d'expérience ») en priorité ; sinon somme des périodes de travail, sans la partie formation et en fusionnant les périodes qui se chevauchent.

4.3 Classement par domaine

Le domaine est déterminé en quatre étapes, de la plus sûre à la plus large :

1. **CV déjà validé** : si un CV presque identique a déjà été validé par un recruteur, son domaine est repris.
2. **Intitulé de poste en tête de CV** : recherche d'un des 59 intitulés connus (comptable, développeur, ingénieur génie civil…) dans les 15 premières lignes. Confiance : 85 %.
3. **Intitulé de poste ailleurs dans le CV** : même recherche sur tout le texte. Confiance : 70 %.
4. **Modèle statistique** : sinon, un modèle d'apprentissage automatique (TF-IDF et Naive Bayes), entraîné sur les mots-clés des 50 domaines et sur les CV validés, propose le domaine le plus probable.

Les intitulés sont recherchés en mots entiers, et certains contextes sont exclus (par exemple « serveur Windows » n'est pas un métier de la restauration).

4.4 Score sur 100

Critère	Points	Calcul
Diplôme	30	Doctorat 30, Master/Ingénieur 25, Licence 15, BTS/DUT 10, Bac 8
Expérience	40	De 8 points (1 an) à 40 points (10 ans et plus)
Complétude	30	Nom, prénom, email, téléphone, compétences et ville renseignés

4.5 Validation humaine

Un CV est envoyé dans la file de validation s'il n'a pas pu être classé, si la confiance est inférieure au seuil (70 % par défaut, réglable de 30 à 95 %) ou si au moins deux informations sont incertaines.

4.6 Apprentissage

Chaque domaine validé est enregistré (prédiction et choix final), ce qui permet de mesurer la précision réelle du modèle. Si l'option « Apprendre de cette décision » est cochée, le texte du CV rejoint les données d'entraînement (avec un poids triple) et le modèle est réentraîné, automatiquement ou à la demande. Les correspondances prénom et sexe apprises sont aussi mémorisées.

5. Architecture technique

5.1 Technologies

Besoin	Outil
Interface web	Streamlit 1.41 et plus (Python)
Lecture des documents	PyMuPDF, python-docx, RapidOCR (ONNX, sans PyTorch)
Classement	scikit-learn (TF-IDF, Naive Bayes), NumPy
Exports	pandas, openpyxl (Excel)
Messagerie	imaplib (bibliothèque standard Python)

5.2 Organisation du code (environ 3 200 lignes)

Fichier	Contenu
`app.py`	Application principale : domaines et métiers, extraction, classement, score, apprentissage et les neuf pages.
`ui.py`	Charte graphique : couleurs, icônes, logo, CSS et composants d'affichage.
`gestionnaire_email.py`	Client IMAP : récupération des pièces jointes et déplacement des emails traités.

`CLASSEURS.py`	Ancienne version de l'application, conservée pour référence.
`test_email.py`, `test_ocr.py`, `debug_cv.py`	Scripts de vérification manuelle (connexion mail, OCR, détection du nom).

5.3 Données produites

Dossier ou fichier	Contenu
`cv_a_traiter/`	Dossier d'entrée par défaut
`cv_recus_email/`	Pièces jointes téléchargées depuis la boîte mail
`CV_classes/`	Copies des CV rangées par domaine (et par métier pour les CV reçus par email)
`CV_filtres/`	Sélections enregistrées depuis la page Filtrer
`exports/`	Exports Excel
`apprentissage.json`	Décisions et CV validés (données personnelles)
`config_email.json`	Identifiants de messagerie saisis dans l'application

> Tous ces dossiers et fichiers sont exclus du dépôt git, car ils contiennent des CV, des données personnelles ou des mots de passe.

6. Travaux réalisés sur la version 1.2

Une revue complète du code a permis de corriger les points suivants :

Domaine	Correction
Classement	Intitulés de poste cherchés en mots entiers (« budget » ne donnait plus « Directeur Général ») ; « ingénieur » seul n'envoie plus tous les ingénieurs en Génie Civil ; contextes exclus (« serveur Windows », « centre commercial »).
Âge	Les dates d'expérience ne sont plus prises pour des dates de naissance ; « stage : 6 mois » n'est plus lu comme un âge.
Sexe	Les pronoms « il » et « elle » ne servent plus d'indice ; la civilité n'est lue que dans l'en-tête, pas dans les références.
Expérience	Les années d'études ne sont plus comptées ; les périodes sont additionnées au lieu d'en prendre la médiane.
Apprentissage	La réinitialisation repartait parfois d'un ancien modèle en mémoire ; corrigé.
Lecture	Un CV remplacé par un autre portant le même nom est désormais relu.
Emails	Plus de téléchargements en double ; emails non marqués comme lus ; seul l'email traité est déplacé ; un email dont le CV est illisible reste dans la boîte ; ajout d'une barre de recherche.
Interface	Logo Cible RH affiché dans le menu et utilisé comme icône d'onglet ; OCR passé de 100 à 200 dpi.
Confidentialité	Le fichier d'apprentissage, qui contient des extraits de CV, n'est plus suivi par git.

Nettoyage	Suppression du code et des fichiers inutilisés, suppression des calculs en double.

Ces corrections ont été vérifiées par 23 tests sur des exemples ciblés, et chaque page de l'application a été ouverte en mode test sans erreur.

7. Limites et recommandations

Limites actuelles

- L'extraction repose sur des règles : les CV à la mise en page inhabituelle (colonnes, tableaux, texte en image) peuvent donner des informations incomplètes.
- Les listes de villes, de nationalités et de prénoms sont centrées sur le Cameroun, la France et l'Afrique francophone.
- La correspondance avec une offre compte les mots communs : elle ne comprend pas les synonymes.
- Les fichiers `.doc` (ancien format Word) ne sont pas lus.
- Le mot de passe de messagerie saisi dans l'application est enregistré en clair dans un fichier local.

Recommandations

1. **Tester sur un lot réel de CV** et sur la vraie boîte mail, puis valider les premiers résultats pour alimenter l'apprentissage.
2. **Découper** `app.py` (2 600 lignes) en modules : données, extraction, classement, pages.
3. **Ajouter des tests automatisés** sur un jeu de CV anonymisés pour mesurer la précision à chaque évolution.
4. **Enrichir les référentiels** (villes, prénoms, métiers) à partir des corrections des recruteurs.
5. **Protéger les identifiants** de messagerie (coffre de mots de passe du système plutôt que fichier en clair).

8. Installation et lancement

1. Installer Python 3.10 ou plus récent.
2. Créer un environnement virtuel et installer les dépendances : `pip install -r requirements.txt`
3. Lancer l'application : `streamlit run app.py` (elle s'ouvre sur `http://localhost:8501`).
4. Déposer les CV dans `cv_a_traiter/` puis cliquer sur « Lancer l'analyse » dans la page Analyser.
5. Pour la messagerie : renseigner le serveur IMAP, l'adresse et un mot de passe d'application dans Paramètres, puis cliquer sur « Tester la connexion ».